Graduação em Ciência de Dados e Inteligência Artificial

DISCIPLINA: Extração e Preparação de Dados

Professor: Pedro Calais

E-mail: pedro.calais@gmail.com

Contexto

Recentemente, a DoorDash publicou uma forma interessante de automatizar a transcrição de cardápios a partir de fotos, usando combinações de OCR + LLMs e estratégias com modelos multimodais + camadas de *guardrails* (camadas de verificação) para garantir qualidade. A DoorDash – uma espécie de iFood/Rappi norte-americana – montou um pipeline pensado para estruturar itens, categorias, atributos e decidir quando delegar para revisão humana.

Os detalhes da implementação da DoorDash podem ser encontrados em:

- https://careersatdoordash.com/blog/doordash-llm-transcribe-menu/
- https://blog.bytebytego.com/p/how-doordash-uses-ai-models-to-understand

Recomendo que leiam estes documentos com atenção para apropriar-se do problema e da solução.

O objetivo desta atividade é que vocês construam uma **prova de conceito (POC)** inspirada nesse pipeline: extrair dados estruturados de cardápios obtidos da internet e armazená-los de forma persistente, utilizando o **Prefect** como orquestrador do fluxo de dados em Python.

Orquestração e Pipeline (Prefect)

Para organizar e automatizar as etapas de extração, transformação e validação, o pipeline deve ser construído em Python e **orquestrado nativamente com a biblioteca Prefect**.

- Cada etapa do pipeline deve ser modelada como uma **@task** do Prefect (ex: extração/OCR, estruturação com LLM/Multimodal, validação com Great Expectations e armazenamento).
- O fluxo completo deve ser orquestrado por um **@flow** do Prefect.
- Espera-se que o grupo utilize recursos nativos do Prefect, como controle de dependências entre tarefas e registro de logs da execução.

Front-End

Construa uma interface gráfica interativa utilizando **Streamlit** ou **Gradio** que permita ao usuário carregar uma foto de cardápio, disparar a execução do fluxo no Prefect e visualizar o resultado do processamento estruturado.

Qualidade de Dados (Guardrails)

O pipeline deverá incluir uma camada explícita de qualidade de dados utilizando a ferramenta **Great Expectations**, integrada diretamente como uma tarefa (@task) dentro do fluxo do Prefect.

- O grupo deverá definir expectativas (regras de validação) para os dados gerados, como: verificação de preços válidos e positivos, ausência de campos obrigatórios nulos, consistência entre categorias e itens, formatos corretos de texto e detecção de possíveis duplicidades ou inconsistências.
- Essas validações devem funcionar como uma camada de “guardrails” semelhante às estratégias utilizadas pela DoorDash para aumentar a robustez do sistema.
- Além disso, o relatório da entrega deverá apresentar um balanço quantitativo extraído dos testes em larga escala, reportando obrigatoriamente:
    1. O **percentual de *missing data*** (campos obrigatórios ausentes ou nulos após a extração).
    2. O **percentual de valores de preço dentro de valores razoáveis** (identificando alucinações de OCR/LLM que geraram preços absurdos ou negativos).
    3. O **tempo médio de processamento por cardápio (latência):** Medir quantos segundos o pipeline leva do upload da imagem até a persistência no banco ou CSV, permitindo avaliar a eficiência operacional da abordagem escolhida.
    4. O **custo estimado por execução (se utilizarem APIs pagas):** Calcular o consumo médio de tokens ou o custo em dólares por cardápio processado, aproximando os alunos de problemas reais de custo de IA em produção.

Objetivos

Definir e executar um pipeline de ETL estruturado com Prefect contendo:

1. **Entrada:** Um conjunto de **pelo menos 50 cardápios obtidos da Web** (imagens de cardápios de restaurantes locais, redes ou imagens públicas com estruturas variadas, colunas, layouts complexos e ruídos visuais).
2. **Etapa de Extração:** Usar OCR para extrair texto bruto ou usar modelo multimodal para entender diretamente da imagem.
3. **Etapa de Estruturação:** Processar esse texto bruto/imagem para identificar categorias, itens, descrições, preços e atributos adicionais, corrigindo possíveis erros de layout.
4. **Validação:** Aplicar as regras do Great Expectations na tarefa de validação.

5. **Armazenamento:** Salvar os dados estruturados e validados em um banco de dados **SQLite** ou em uma **planilha CSV consolidada** que vai sendo atualizada por *append* a cada cardápio processado.
6. **Avaliação em Larga Escala:** Processar o lote de 50 cardápios, documentar os resultados consolidados (métricas de erro, taxa de missing data, preços razoáveis, latência e custos) e analisar onde o pipeline funciona bem ou falha.

Abordagens de Extração/Estruturação (Escolha uma):

- **Abordagem 1 (OCR + LLM):** Primeiro extrai texto via OCR (ex.: Tesseract, EasyOCR, DeepSeek-OCR), depois usa um modelo de linguagem (via API ou open source) para converter em estrutura JSON.
- **Abordagem 2 (Modelo Multimodal):** Usar um modelo multimodal (ex.: Gemini) que recebe a imagem + prompt para gerar a saída estruturada diretamente.

Entregáveis e Avaliação

1. **Apresentação (20% da nota):** Apresentação da solução, arquitetura do pipeline e demonstração prática.
2. **Código do Pipeline e Orquestração (20% da nota):** Código Python limpo e estruturado com @flow e @tasks do Prefect, além da interface gráfica (Streamlit/Gradio).
3. **Banco SQLite ou Planilha CSV Resultante (20% da nota):** Arquivo SQLite povoado ou arquivo CSV consolidado com os cardápios estruturados por *append*, acompanhado do dicionário de dados/esquema explicativo.
4. **Avaliação Prática e Relatório de Qualidade (20% da nota):** Documentação contendo o resultado da execução dos 50 cardápios da Web, incluindo as métricas consolidadas (**% de *missing data***, **% de preços razoáveis**, **latência média** e **custo estimado**), discussão de falhas e causas (layout, ruído, alucinação).
5. **Execução ao Vivo (20% da nota):** O professor escolherá fotos aleatórias de cardápios durante a apresentação e executará o pipeline do grupo com elas.

Bom trabalho!

Pedro Calais